NEU-DET 钢材表面缺陷检测模型测试报告

YOLO26n 微调、独立测试集评估与网页演示

2026 年 10 月 24 日

项目仓库：`https://github.com/lapwing119/YOLO-NEU-DET`

报告摘要

本报告记录基于 NEU-DET 数据集微调 YOLO26n 的流程、数据检查结果、独立测试集指标和 Flask 网页演示情况，并为项目汇报与验收讲解提供术语解释。模型检测六类钢材表面缺陷。当前记录的独立测试结果为 Precision 0.719、Recall 0.674、mAP@0.5 0.739、mAP@0.5:0.95 0.401。网页已成功加载训练权重，并完成图片上传、预测框、类别、置信度和坐标展示。

验收标准未给出数值门槛，因此本报告如实提供测量值，不将其表述为达到某个未规定的合格线。指标描述的是当前数据划分、训练设置和权重在 NEU-DET 测试集上的结果。

1 项目概览与验收对应

项目项	本项目内容
任务	钢材表面缺陷目标检测，同时预测缺陷类别和所在位置
模型	YOLO26n，使用预训练权重开始微调
数据	NEU-DET，6 类，1800 张图像及对应 XML 标注
数据划分	训练集 1440 张、验证集 180 张、测试集 180 张
交付推理权重	`weights/best.pt`，约 5.21 MB
演示方式	Flask 本机网页，地址 `http://127.0.0.1:5000`

验收项目	当前证据与状态
环境部署	本机 Windows 环境已验证 CUDA 可用；Flask 启动并成功加载 `weights/best.pt`。尚未在另一台干净电脑上复现部署。
数据处理	1800 张图像和 1800 份 XML 已检查；转换后 train/val/test 数量与标签数量检查通过。
六类识别	`data.yaml` 包含 6 类；独立测试输出了六类分项指标。
模型微调	已使用 NEU-DET 完成 YOLO26n 微调，保存 `best.pt`。
独立测试	对 180 张 test 图片计算了 Precision、Recall、mAP@0.5 和 mAP@0.5:0.95。

可视化展示	网页上传图片成功，显示框、类别、置信度和框坐标；已用 `crazing` 图片演示。
代码及权重	本地 Git 提交并成功推送至 GitHub；记录中包含代码和 `best.pt`。
文档与讲解	README 与模型测试结果文件已提交；本报告补充流程解释、术语和答辩稿。

2 开发与运行环境

组件	本机验证信息
操作系统	Windows 环境，系统报告显示 Windows 10.0.26200
Python	3.11.9，项目独立虚拟环境 `.venv`
PyTorch	2.12.1+cu132，`torch.version.cuda` 显示 13.2
GPU	NVIDIA GeForce RTX 4050 Laptop GPU，约 6140 MiB 显存
Ultralytics	8.4.182
Flask	3.1.3

环境检查时 `torch.cuda.is_available()` 返回 `True`, Ultralytics 检查识别到 CUDA:0 和 RTX 4050。这证明开发电脑能使用 GPU，不等于已在其他电脑完成独立部署验证。

3 数据准备与标注检查

3.1 数据类别

NEU-DET 原始数据由灰度钢材表面图像和 Pascal VOC 风格 XML 标注组成。XML 文件记录图像文件名、尺寸、缺陷类别和矩形框坐标。项目检测以下类别:

类别编号	类别名称
0	`crazing`（龟裂）
1	`inclusion`（夹杂）
2	`patches`（斑块）
3	`pitted_surface`（麻点）
4	`rolled-in_scale`（氧化铁皮）
5	`scratches`（划痕）

3.2 XML 转 YOLO 标签

每个 XML 中的矩形框通常以左上角 $(x_{\min}, y_{\min})$ 和右下角 $(x_{\max}, y_{\max})$ 表示。YOLO 检测标签每行记录 “类别编号、中心点 x、中心点 y、框宽、框高”。中心点和宽高相对于图像尺寸归一化，因此坐标通常在 0 到 1 之间。

概念公式为:中心点 $x = (x_{\min}+x_{\max})/2$,中心点 $y = (y_{\min}+y_{\max})/2$,框宽 $= x_{\max}-x_{\min}$,框高 $= y_{\max}-y_{\min}$; 随后分别除以图像宽度或高度进行归一化。实际坐标边界处理由 `prepare_dataset.py` 执行。

3.3 划分与质量检查

划分	图片数	标签数	目标框数	用途
train	1440	1440	3335	用于模型学习
val	180	180	441	训练过程中验证和选择权重
test	180	180	413	训练结束后进行独立评估

标签检查确认：图像与标签文件名相匹配；每行标签含 5 个字段；类别编号在 0 至 5 范围内；归一化坐标在 0 至 1 范围内；框宽和框高均大于 0。

3.4 `data.yaml` 的作用

`dataset/data.yaml` 是数据集索引和类别说明文件，不保存图片、标签内容或模型权重。它告诉 Ultralytics 数据集根目录在哪里、训练/验证/测试图片分别在哪个子目录，以及类别编号对应的名称。当前 `path` 使用 `C:/wlkq/YOLO-NEU-DET/dataset`，是本机绝对路径。在本机可用；其他电脑需要运行 `prepare_dataset.py` 重新生成配置或相应调整路径。

```
path: C:/wlkq/YOLO-NEU-DET/dataset
train: images/train
val: images/val
test: images/test
names:
  0: crazing
  1: inclusion
  2: patches
  3: pitted_surface
  4: rolled-in_scale
  5: scratches
```

4 YOLO26n 微调流程

4.1 预训练与微调

`yolo26n.pt` 是训练起点的预训练权重。预训练模型已经从其他图像任务中学到通用视觉特征；微调是在此基础上继续用 NEU-DET 图像和缺陷框训练，使模型适应六类钢材缺陷。训练过程中，模型把预测结果与人工标签比较形成损失，再通过优化过程调整参数。

训练集用于更新参数；验证集用于监测训练表现并选择模型；测试集保留到训练完成后评估。训练过程中保存的最佳权重是 `best.pt`，本项目将其复制到 `weights/best.pt` 供网页程序加载。

4.2 训练参数

参数	设置	含义
`epochs`	50	最多训练 50 轮；一轮表示遍历一次训练集。
`imgsz`	640	训练与评估时的输入尺寸设置。

batch	4	每次参数更新所用的批量图像数。
device	0	使用第 0 号 CUDA GPU。
workers	0	数据加载工作进程设为 0，适配 Windows 环境。
patience	15	验证表现长期无改善时允许提前停止。

实际训练命令：

```
.\.venv\Scripts\yolo.exe detect train model=yolo26n.pt data=dataset/data.yaml epochs=50
    imgsz=640 batch=4 device=0 workers=0 patience=15 project=runs/detect name=neu_yolo26n
    plots=True
```

5 检测与网页推理流程

目标检测不仅回答“是什么”，也回答“在哪里”。模型为每个预测目标输出边界框、类别和置信度。YOLO26 支持端到端、NMS-free 推理；本报告不假设每次推理都必须执行传统非极大值抑制。

步骤	程序行为	项目对应
1. 上传	用户在网页选择 JPG/JPEG/PNG/BMP 图片。	templates/index.html
2. 接收	Flask 接收表单上传并读取图像。	app.py
3. 加载	程序加载训练权重并调用 Ultralytics 推理。	weights/best.pt
4. 预测	输出候选缺陷框、类别与置信度。	YOLO26n 推理结果
5. 展示	显示带框图片及坐标/类别/置信度表格。	Flask 返回页面

5.1 置信度与阈值

置信度是模型为某条预测给出的分数，用于表示模型对该预测的确信程度；它不是 Precision，也不应解释为经过校准的真实概率。置信度阈值 conf 是保留预测的最低分数门槛。阈值提高通常会减少低分预测，可能减少误报但增加漏检；阈值降低可能找到更多目标，也可能增加误报。

5.2 成功运行案例：网页上传与命令行预测

用户在浏览器访问本机 Flask 页面，上传 crazing_242.jpg 并点击“开始检测”。页面返回成功，显示带框图片及两条目标记录，类别均为 crazing，置信度分别为 49.0% 和 36.3%，并给出边界框坐标。这证明上传、推理、结果图返回和表格展示流程已运行。



图 1: Flask 网页成功处理样例图片并显示预测框、类别、置信度和坐标

序号	类别	置信度	边界框坐标（左上 x, y；右下 x, y）
1	`crazing`	49.0%	55, 0, 183, 54
2	`crazing`	36.3%	11, 130, 197, 198

命令行单图预测也生成了独立带框结果图，便于将模型输出图与网页结果表对应起来。

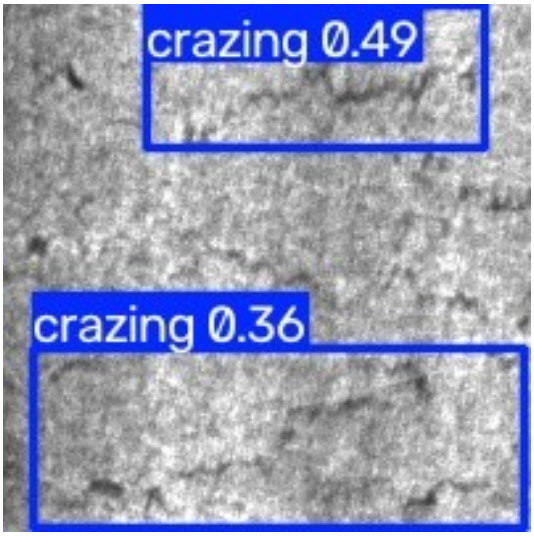


图 2: 命令行 predict 生成的样例预测图

6 独立测试集评估结果

训练完成后，使用 `weights/best.pt` 在 `data.yaml` 指定的 test 划分上评估，共 180 张图片、413 个标注目标框。评估将模型预测与人工标注进行比较，并计算 Precision、Recall 和 AP/mAP。

评估命令（本机路径配置仍有效且权重在 `weights` 文件夹时）：

```
.\.venv\Scripts\yolo.exe detect val model=.\weights\best.pt data=.\dataset\data.yaml
    split=test imgsz=640 batch=4 device=0 workers=0 plots=True
```

6.1 总体指标

指标	结果	初学者解释
Precision	0.719	模型输出的检测中，综合精确率约为 0.719。
Recall	0.674	测试集真实目标中，综合召回率约为 0.674。
mAP@0.5	0.739	IoU=0.5 匹配标准下，六类 AP 的平均值。
mAP@0.5:0.95	0.401	在多个 IoU 标准上平均，更严格衡量框定位。

6.2 各类别指标

类别	图像数	目标数	Precision	Recall	AP@0.5	AP@0.5:0.95
crazing	30	80	0.742	0.362	0.546	0.261
inclusion	36	72	0.785	0.711	0.805	0.482
patches	37	93	0.828	0.882	0.918	0.601
pitted_surface	30	46	0.912	0.674	0.810	0.408
rolled-in_scale	30	62	0.548	0.500	0.590	0.242
scratches	30	60	0.498	0.917	0.769	0.412

各类别图像数合计可超过 180，因为一张图片可能包含多个类别。AP@0.5:0.95 分项数值按评估结果图记录；总体值为 0.401。

6.3 测试评估图示

Precision-Recall 曲线展示不同召回水平下的精确率变化。图例中的各类数值是 AP@0.5，粗蓝线给出总体 mAP@0.5=0.739。

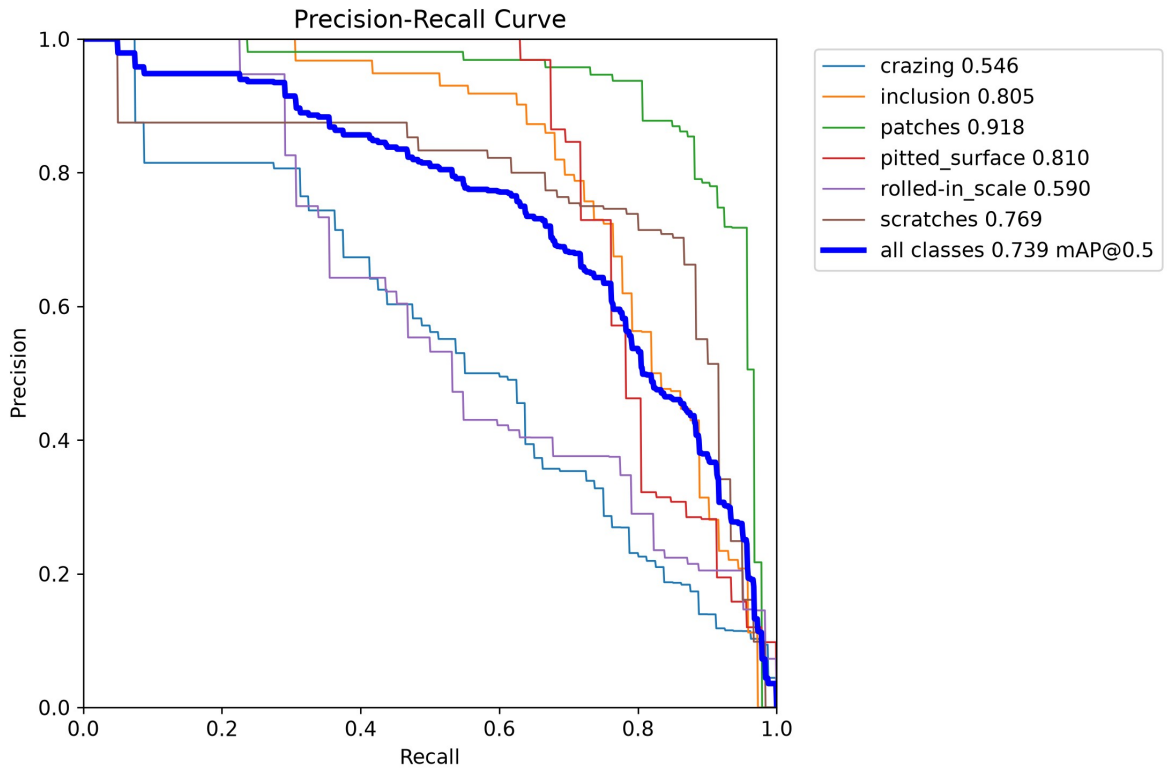


图 3: 独立测试集 Precision-Recall 曲线及各类别 AP@0.5

混淆矩阵横轴为真实类别，纵轴为预测类别；对角线表示正确类别匹配，非对角线表示类别混淆。background 行或列表示未匹配的标注或预测。阅读时应结合坐标轴方向理解，不宜只看单个格子的绝对计数。

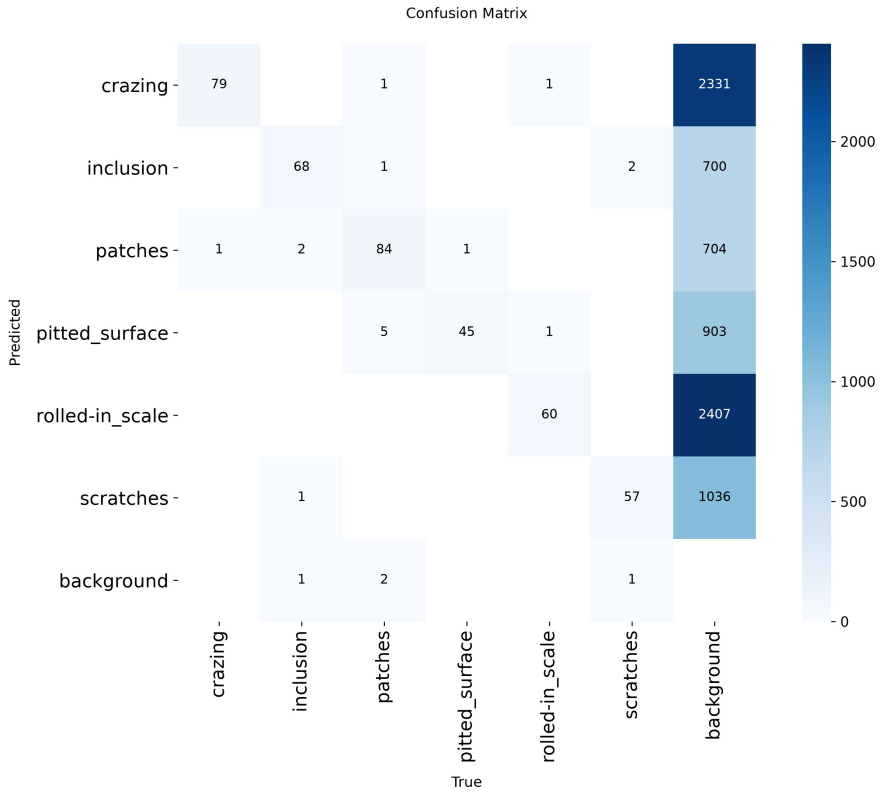


图 4: 独立测试集混淆矩阵（原始计数）

7 指标术语解释与结果解读

7.1 IoU

IoU（Intersection over Union，交并比）衡量预测框与人工标注框的重叠程度。IoU 越高，两个框越重合。评估通常要求类别正确且预测框达到指定 IoU 标准，才把预测与真实标注匹配。

7.2 Precision 与 Recall

Precision（精确率）关注模型报出的缺陷有多少正确；Precision 偏低通常意味着误报较多。Recall（召回率）关注人工标出的缺陷有多少被模型找到；Recall 偏低通常意味着漏检较多。两者需要一起看，因为放宽预测标准可能提高 Recall，同时也可能引入更多误报。

7.3 AP 与 mAP

AP（Average Precision，平均精度）是单个类别在不同置信度门槛下 Precision/Recall 表现的综合指标。mAP（mean Average Precision，平均 AP）是对各类别 AP 取平均。mAP@0.5 中的 0.5 是预测框匹配用的 IoU 门槛，不是置信度阈值。mAP@0.5:0.95 对多个 IoU 门槛求平均，因此对边界框定位更严格。

7.4 结果解读

- `patches` 的 AP@0.5 为 0.918，是本次六类中最高的类别结果。
- `crazing` 的 Recall 为 0.362，`rolled-in_scale` 的 AP@0.5 为 0.590，是值得优先检查的类别。

- scratches 的 Recall 为 0.917，但 Precision 为 0.498，表示找到较多标注目标，同时未匹配预测也较多。
- 总体 mAP@0.5 为 0.739，而 mAP@0.5:0.95 为 0.401，说明在更严格的框重合标准下，定位质量仍有改进空间。

这些现象可能与类别纹理相似、样本数量、缺陷形态和边界框标注方式有关；仅凭指标不能确定具体原因，需要结合错误案例和标注复查。

8 交付文件与复现说明

文件或目录	用途
app.py	Flask 图片上传和模型预测服务。
templates/index.html	网页上传、结果图和表格展示页面。
prepare_dataset.py	解析 XML、生成 YOLO 标签与数据配置。
requirements.txt	Flask、Ultralytics、Pillow 等项目依赖。
weights/best.pt	本项目微调后用于推理的模型权重，约 5.21 MB。
dataset/data.yaml	数据路径和类别名称配置；当前使用本机绝对路径。
README.md 与模型测试结果	安装运行说明和指标记录。

原始数据集、虚拟环境、训练运行目录和临时预测结果被.gitignore 排除，没有随代码仓库提交。重新训练需要按数据来源要求取得 NEU-DET 数据，并在本机运行数据准备脚本。requirements.txt 未固定 CUDA 版 PyTorch；新电脑应先依据 GPU/CUDA 环境安装合适的 PyTorch，再安装项目 requirements.txt。

8.1 本机启动演示

```
Set-Location C:\wlkq\YOLO-NEU-DET
.\.venv\Scripts\python.exe .\app.py
```

启动后在浏览器访问 http://127.0.0.1:5000。本地址绑定本机，只用于本机演示。

8.2 已知范围与复现注意事项

- 当前验证的是开发电脑本机运行，尚未记录在另一台新电脑或干净环境中从 GitHub 克隆并独立部署的结果。
- data.yaml 的 path 是本机路径；其他电脑应重新准备数据并运行 prepare_dataset.py，或调整路径后再训练/评估。
- NEU-DET 图像未包含在仓库中；使用者需自行取得数据并遵守其发布方的使用条件。
- 本机网页地址为 127.0.0.1，不代表已部署为可供公网访问的服务。
- 报告只陈述实际记录的参数和输出；课程未提供数值达标阈值。

9 汇报讲解稿与常见追问

9.1 讲解稿

“我的项目是基于 YOLO26n 的 NEU-DET 钢材表面缺陷检测。数据包含六类缺陷，原始 XML 标注记录类别和矩形框。我使用 prepare_dataset.py 转换成 YOLO 标签，检查文件名、类别编号和归一化坐标，并整理为 1440 张训练图片、180 张验证图片和 180 张独立测试图片。

训练时从 yolo26n.pt 预训练权重开始，用训练集继续微调，最多 50 轮，输入尺寸 640，batch 为 4，并由验证集监测效果、选择最佳权重。最终推理使用 weights/best.pt。

训练完成后，我在独立测试集 180 张图片上评估，得到 Precision 0.719、Recall 0.674、mAP@0.5 0.739 和 mAP@0.5:0.95 0.401。Precision 表示预测结果的精确程度，Recall 表示真实缺陷被找到的程度，mAP 是跨类别和置信度情况综合得到的检测指标。

程序方面，我用 Flask 做了本机网页。用户上传图片后，程序加载 best.pt，显示检测框、类别、置信度和坐标。单张 predict 演示用来展示功能，完整测试集指标来自 detect val 的 test 划分。”

9.2 常见问题

问题	回答要点
yolo26n.pt 和 best.pt 有何区别?	yolo26n.pt 是训练起点的预训练权重；best.pt 是在 NEU-DET 上微调后保存的最佳权重。
为什么分训练、验证、测试?	训练集更新模型；验证集帮助监测和选权重；测试集留到最后评估泛化表现。
conf=0.25 和 mAP@0.5 的 0.5 一样吗?	不一样。conf 是预测保留门槛；mAP@0.5 的 0.5 是预测框与标注框匹配时的 IoU 门槛。
单张图片预测能证明 mAP 吗?	不能。单张预测展示程序；mAP 要将整组测试图片的预测与人工标注比较后计算。
模型能保证所有钢材图像都正确吗?	不保证。指标只代表当前测试集和设置；其他成像条件和数据需要另行验证。

10 术语表

术语	通俗解释
目标检测	判断图片里有什么目标，并给出目标位置。
标注 / Ground Truth	人工给出的类别和目标框，作为训练答案与评估标准。
预训练权重	模型在其他数据上学到的参数，作为本次训练起点。
微调 Fine-tuning	在预训练模型基础上，用本项目数据继续训练。
Epoch	训练集被模型完整学习一遍。
Batch size	一次处理并用于更新模型参数的样本数量。
置信度 Confidence	模型为某一条预测输出的评分。
置信度阈值	用于决定哪些预测被保留或显示的最低分数门槛。
IoU	预测框和人工框的重合程度度量。
Precision	预测为缺陷的结果中，正确结果所占比例。

Recall	人工标注的真实缺陷中，被模型检出的比例。
AP / mAP	单类平均精度 / 多类别 AP 的平均值。
CUDA	NVIDIA GPU 计算平台；本机检查确认 PyTorch 可使用 CUDA。
权重文件	保存模型学习参数的文件；本项目推理加载 best.pt。

参考资料

- Ultralytics 目标检测文档：`https://docs.ultralytics.com/tasks/detect`
- Ultralytics YOLO26 文档：`https://docs.ultralytics.com/models/yolo26`
- Ultralytics 验证与预测文档：`https://docs.ultralytics.com/modes/val/`；`https://docs.ultralytics.com/modes/predict/`
- 项目数据、训练命令、测试结果和网页运行情况：依据项目操作记录、终端输出和用户提供的结果截图整理。